

PolicyPulse

Precision Semantic Role Extraction for
Enhanced Privacy Policy Comprehension

Andrick Adhikari · Sanchari Das · Rinku Dewri
University of Denver

NDSS 2025 · Paper Review · 2026.05

MK4MAX44

목 차

01	Introduction & State of the Art
02	Methodology
03	Results & Analysis
04	Conclusion
05	Q & A
06	References

Table of Contents

논문	PolicyPulse — NDSS 2025
저자	Adhikari · Das · Dewri (Univ. of Denver)
주제	개인정보처리방침 자동 정보 추출 (SRL 기반)
규모	129,856개 정책 / 3,970만 프레임 분석
성능	Weighted Avg F1 = 0.97
발견	60% 정책이 USER_MECHANISM 미기재

Introduction

& State of the Art

- ▶ 연구 배경: 개인정보처리방침의 비효율성
 - 평균 70문장의 복잡한 법률 언어로 작성 → 사용자 대부분 이해 못 한 채 동의
 - 가독성·보호성·접근성 세 가지 모두 문제
- ▶ 기존 NLP 도구의 한계
 - 단락 수준 분류에 그침 → "데이터 수집 항목 있냐 없냐" 수준만 제공
 - 누가(FIRST_PARTY), 무엇을(DATA), 어떻게(MECHANISM) 세부 추출 불가
 - 특정 태스크 하나에만 특화 → 다른 응용에 재사용 불가
- ▶ 제안: PolicyPulse
 - SRL(Semantic Role Labeling) 기반 세밀한 정보 추출 파이프라인
 - 분류에서 끝내지 않고 문장 내 누가·무엇을·왜·어떻게를 역할 단위로 자동 추출
 - 범용 플랫폼 → 완전성 검사·요약 생성·Q&A·선호도 확인 등 다양한 응용 지원

- ▶ 분류(Classification) 기반
 - Polisis (Harkous et al., USENIX 2018): OPP-115 기반 단락 수준 분류
 - 높은 정확도이나 누가·무엇을·어떻게는 알 수 없음
- ▶ 정보 추출(Information Extraction) 기반
 - PoliGraph (Cui et al., USENIX 2023): NER로 데이터 유형·주체·관계 그래프 추출
 - PolicyLint / PoliCheck: 정책 내 모순·앱 행동 불일치 탐지 특화
- ▶ SRL 기반 (선행 연구)
 - Bhatia et al. (2016): 5개 정책 202문장 수작업 코딩 → 자동화 없음
 - PurPliance: 목적 절에만 SRL 적용, FPCU 범위로 제한
- ▶ 결론 — PolicyPulse의 위치
 - 기존 도구: 단일 태스크 특화 또는 자동화 미비
 - PolicyPulse: 분류 + 자동 SRL 결합 → 다목적 정보 추출 플랫폼

Methodology

- ▶ Step 1 — SRL: AllenNLP SRLBert로 문장에서 프레임 추출
 - PropBank 기반 사전 학습 (약 50,000 술어) — fine-tuning 불필요
 - 정책당 평균 70문장 × 문장당 약 4 프레임 → 정책당 평균 305.7 프레임
- ▶ Step 2 — 프레임 분류: XLNet 2단계 분류기
 - Level 1: SKIP vs KEEP (개인정보 무관 vs 관련)
 - Level 2: KEEP 프레임을 FPCU · TPSC · UCC · UAED · DR 중 하나로 분류
- ▶ Step 3 — 프라이버시 역할 매핑: PropBank → 16가지 전용 역할
 - FIRST_PARTY_ENTITY · DATA · MECHANISM · PURPOSE · USER_MECHANISM 등
- ▶ Step 4 — 대규모 적용: Princeton Privacy Crawl 129,856개 정책
 - 총 39,702,767개 프레임 처리 → 정책 완전성 분석




Fig. 1. Overview of privacy-specific role extraction in PolicyPulse

Fig.1 흐름

- ▶ ① 입력 문장에서
SRL이 프레임 추출
- ▶ ② 각 프레임을 FPCU/
SKIP 등으로 분류
- ▶ ③ KEEP 프레임의 인수를
프라이버시 역할로 변환

논문 예시 문장

- ▶ "We may collect location
information through
cookies when you use
our service"
- frame1: include → FPCU
- frame2: use → SKIP
- frame3: collect → FPCU
- ▶ → ARG0=FIRST_PARTY
- ▶ → ARG1=DATA
- ▶ → ARGM-MNR=MECHANISM

레이블	설명	F1 (Two-Level)
SKIP	개인정보 무관 프레임 — 학습 데이터의 72.6% / 실제 분석의 약 90%	0.98
FPCU	First Party Collection/Use — 1자 데이터 수집·사용	0.98
TPSC	Third Party Sharing/Collection — 제3자 공유·수집	0.98
UCC	User Choice/Control — 사용자 선택권·통제 (옵트인/아웃)	0.98
UAED	User Access/Edit/Deletion — 사용자 데이터 접근·수정·삭제	0.98
DR	Data Retention — 데이터 보존 기간	0.96

실제 학습 데이터 분포: SKIP 10,401 / FPCU 1,417 / TPSC 1,230 / UCC 556 / UAED 182 / DR 160 → 저빈도 클래스 증강 필요

Category	Frame			Frame with sentence context (FSC)			FSC with custom attn. mask			FSC augmented			FSC augmented (ensemble)			FSC augmented (two-level)		
	pr	re	f1	pr	re	f1	pr	re	f1	pr	re	f1	pr	re	f1	pr	re	f1
SKIP	0.96	0.90	0.93	0.94	0.93	0.93	0.85	0.95	0.89	0.95	0.90	0.92	0.95	0.92	0.93	0.99	0.98	0.98
FPCU	0.67	0.83	0.72	0.56	0.64	0.56	0.29	0.43	0.33	0.70	0.76	0.72	0.78	0.82	0.79	0.92	0.95	0.93
TPSC	0.70	0.77	0.70	0.59	0.71	0.59	0.38	0.36	0.34	0.70	0.74	0.75	0.79	0.84	0.79	0.92	0.94	0.93
UAED	0.36	0.10	0.15	0.37	0.18	0.20	0.22	0.18	0.16	0.75	0.97	0.84	0.62	0.70	0.65	0.93	0.93	0.92
UCC	0.74	0.79	0.74	0.52	0.61	0.56	0.31	0.30	0.29	0.78	0.96	0.86	0.74	0.80	0.76	0.93	0.93	0.93
DR	0.25	0.23	0.24	0.50	0.33	0.32	0.39	0.18	0.23	0.71	0.99	0.83	0.64	0.68	0.65	0.89	0.95	0.92
macro avg	0.61	0.61	0.58	0.58	0.57	0.53	0.41	0.40	0.37	0.77	0.89	0.82	0.74	0.79	0.76	0.93	0.95	0.94
weighted avg	0.88	0.86	0.86	0.84	0.86	0.84	0.72	0.80	0.74	0.89	0.88	0.88	0.90	0.89	0.89	0.97	0.97	0.97

TABLE I
XLNET NESTED CROSS-VALIDATION PERFORMANCE SCORES FOR DIFFERENT FRAME CLASSIFICATION TRAINING METHODS. PR: PRECISION, RE: RECALL, F1: F1-SCORE

uses two instances of XLNet. The evaluations employed a 10-fold cross-validation approach, utilizing a 9:1 train:test split ratio. The training and test data sets were maintained consistently across all methods. For each configuration, the XLNet model was trained for 6 epochs, utilizing a random 9:1 train:validation split on the training data set. We chose a 6 epoch training duration as, beyond this, validation loss rises while training loss still decreases, suggesting overfitting to training data. Following 6 epochs per fold, the optimal model (selected via validation loss) was tested, providing 10 performance estimates that we average for a final value.

3) *Performance Evaluation:* The average precision (pr), recall (re), and F1-score (f1) of all the methods are shown in Table II. The initial approach used only the frames’ text as input for model training (‘Frame’ column of Table I). While achieving a strong F1-score of 0.93 for the SKIP category, performance was notably low for other categories. Particularly, the UAED and DR categories exhibited F1-scores of only 0.15 and 0.24, respectively. Sentence context can significantly influence the frame category. Therefore, we next explored two methods to introduce such contexts in the model–(i) ‘Frame with sentence context (FSC)’: frame text combined with the sentence, and (ii) ‘FSC with custom attn. mask’: same as the previous but with addition of a custom attention mask for the XLNet input layer. The attention mask assigns a value of 0 to sentence phrases that are not present in the frame. Both methods show improved precision for the DR category, but there is an overall precision drop in all categories for method (ii). Method (i) also did not yield much performance improvement.

Variation in category performance shows influence of instance frequency during training. This is particularly apparent in the consistent superior precision and recall of the SKIP category, which has the highest instance frequency. To tackle

Category	pr	re	f1
LEVEL 1			
SKIP	0.99	0.98	0.98
KEEP	0.93	0.96	0.94
macro avg	0.96	0.97	0.96
weighted avg	0.97	0.97	0.97
LEVEL 2			
FPCU	0.98	0.98	0.98
TPSC	0.99	0.98	0.98
UAED	0.98	0.98	0.98
UCC	0.98	0.98	0.98
DR	0.96	0.97	0.96
macro avg	0.98	0.98	0.98
weighted avg	0.98	0.98	0.98

TABLE II
XLNET NESTED CROSS-VALIDATION PERFORMANCE SCORES FOR LEVEL 1: SKIP-KEEP BINARY CLASSIFICATION AND LEVEL 2: FPCU, TPSC, UCC, UAED, AND DR CLASSIFICATION WITHIN KEEP FRAMES. PR: PRECISION, RE: RECALL, F1: F1-SCORE

context, with synthetically generated training instances for low frequency categories. This approach proved to be effective in distinguishing between closely related frame categories such as UCC and UAED, or FPCU and TPSC, where differentiation is often challenging. Notably, precision and recall also remained consistent regardless of the category.

The disparity in the F1-scores, especially between SKIP frame identification and the rest (KEEP category), indicates the need to better discriminate between them. This prompted us to explore a two-level approach. The first level performed a binary classification to identify SKIP vs. KEEP frames, and the second level predicted the practice type from the five selected categories for KEEP frames. The two levels are realized as two XLNet models, both models trained to classify frames with sentence context. To ensure balance in instance counts, the low-frequency categories were augmented to match the instance count of the highest-frequency category.

TABLE I 핵심

▶ 4가지 방법 F1 비교

- ▶ Frame only
 - UAED F1 = 0.15
- ▶ → 데이터 부족 문제
- ▶ FSC Augmented
 - 증강 후 UAED 0.84
- ▶ → 증강 효과 확인
- ▶ ★ FSC (Two-Level)
 - SKIP 먼저 분리 후
- ▶ 5-class 분류
 - 전체 F1 = 0.97

TABLE II

- ▶ Level1 macro: 0.96
- ▶ Level2 macro: 0.98
- 두 단계 모두 높음

데이터 불균형 문제

- ▶ SKIP이 학습 데이터의 72.6% → 직접 6-class 분류 시 소수 클래스 학습 어려움
 - Two-Level: SKIP vs KEEP 먼저 분리 → KEEP만 따로 5-class 분류 → 집중 학습 가능

데이터 증강의 효과 (UAED: 0.15 → 0.92)

- ▶ UAED(182건)·DR(160건)은 절대적으로 학습 데이터 부족
 - 동의어 교체 + 문맥 기반 단어 치환으로 저빈도 클래스 데이터 보강
 - UAED F1이 약 6배 향상 → 증강이 핵심 역할

XLNet이 BERT보다 나은 이유

- ▶ XLNet: 순열 기반 언어 모델링 → 양방향 문맥 + 자기회귀 특성 동시 활용
 - 프라이버시 정책의 복잡한 조건절 구조 처리에 더 적합
 - 사전 실험에서 BERT 및 전통 분류기 대비 프레임 분류 성능 우수 확인

프라이버시 역할 매핑 (146개 동사 커버)

- ▶ "collect" 동사 (FPCU): ARG0→FIRST_PARTY · ARG1→DATA · ARGM-MNR→MECHANISM
- ▶ 같은 동사라도 카테고리(FPCU/TPSC 등)에 따라 다른 역할로 매핑
- ▶ 16가지 전용 역할: DATA · FIRST_PARTY_ENTITY · MECHANISM · PURPOSE · CONSEQUENCE 등

학습 데이터: OPP-115 기반

- ▶ 115개 웹사이트 → SRLBert로 48,783 프레임 → 최종 13,946개 수동 주석
 - 주석 담당: 경력 3년+ / 독립 검증: 경력 5년+ 2명
 - 10-겹 교차 검증 (9:1 훈련/테스트, 6 epoch 훈련)
- ▶ ▶ 다음 슬라이드: 논문 TABLE III 원본 — 16가지 역할 정의 확인

Results

& Analysis

방법	SKIP	FPCU	TPSC	UCC	UAED	DR	Weighted Avg
Frame only	0.93	0.72	0.70	0.74	0.15	0.24	0.86
FSC Augmented	0.92	0.72	0.74	0.86	0.84	0.83	0.88
FSC (Ensemble)	0.93	0.79	0.79	0.76	0.65	0.65	0.89
★ FSC (Two-Level)	0.98	0.93	0.93	0.93	0.92	0.92	0.97

★ 최종 채택. Level1 macro avg F1: 0.96 / Level2 macro avg F1: 0.98 / 모든 카테고리 precision:recall 0.92 이상

Role	Description
DATA	Information about individuals, users, or subjects, which may include personal, sensitive, or non-personal information
FIRST_PARTY_ENTITY	The organization directly interacting with users, responsible for data collection and use
THIRD_PARTY_ENTITY	An external organization or entity in collaboration with the first-party entity
MECHANISM	The procedures and methods used by first-party or third-party entities to gather user data
PURPOSE	The specific reason for data collection, use and sharing
SHARING_TERMS	The conditions and agreements that govern the sharing of user data with third parties
USER_TRIGGER	Actions or events by users that may trigger data collection, use, or sharing
OPT_IN_MECHANISM	A method or process by which a user can provide explicit consent for the collection or use of their data
OPT_OUT_MECHANISM	A method or process by which a user can choose to decline or stop the collection or use of their data
CONSEQUENCE	The potential outcomes or effects of user choices or actions
USER_MECHANISM	The methods and processes available to users for accessing, editing, and deleting their data
USER_OPERATION	The actions permitted for users to control their data, including access, edit, delete, or management of subsets
RETENTION_PROCESS	The procedures and methods followed by the organization for the storage and management of user data over time
RETENTION_TERMS	The specified terms and conditions that dictate how long user data will be retained by the organization
TIME_PERIOD	A defined duration specifying how long user data will be retained by the organization
LOCATION	The physical or digital location of a particular action; the action can be collection, use, or sharing of data

TABLE III
PRIVACY-SPECIFIC ROLES MAPPED FOR FRAME ARGUMENTS IDENTIFIED BY SEMANTIC ROLE LABELING

주요 역할

- ▶ DATA
 - 개인·민감 정보 총칭
- ▶ FIRST_PARTY_ENTITY
 - 데이터 수집 주체
- ▶ MECHANISM
 - 데이터 수집 방법
- ▶ USER_MECHANISM
 - 사용자가 접근·수정·삭제하는 방법
- ▶ CONSEQUENCE
 - 옵트인/아웃 결과

왜 중요한가

- ▶ 이 역할들이 정책에
- ▶ 얼마나 빠져있는지
- ▶ → 다음 슬라이드

- ▶ 분석 규모
 - 130,604개 웹사이트 → 129,856개 최신 정책 / 총 39,702,767개 프레임 처리
 - 정책당 평균 306 프레임 → KEEP 평균 30개 (약 10%)

정책 완전성 분석: 누락된 핵심 역할

- ▶ 50%: UAED 프레임 자체 없음 — 사용자 데이터 삭제 권리 전혀 미언급
- ▶ 60%: USER_MECHANISM 미기재 — 데이터 접근·수정·삭제 방법 불명확
- ▶ 75%: CONSEQUENCE 미기재 — 옵트인/아웃 결과 불명확
- ▶ 40%: MECHANISM 없음 — 데이터 수집 방법 미기재
- ▶ 20%: USER_TRIGGER 미기재 — 언제 수집되는지 명시 안 함

ChatGPT-3.5 비교

- ▶ ChatGPT: 야후 정책 요약 시 제3자 공유 내용 누락 + 없는 내용 생성 (hallucination)
- ▶ PolicyPulse: 원문 기반 추출 → 환각 없음 / 단, GPT-4 비교는 향후 과제

50%가 UAED 없다는 게 왜 심각한가

- ▶ UAED = 사용자가 자신의 데이터를 접근·수정·삭제할 권리
 - GDPR(유럽)·CCPA(캘리포니아) 등 개인정보보호법이 보장하는 핵심 권리
 - 절반의 사이트가 정책에 이 내용을 아예 명시하지 않는다는 뜻

75%가 CONSEQUENCE 미기재

- ▶ 옵트아웃 버튼 눌렀을 때 "어떻게 되는지" 안 알려줌
 - 마케팅 수신 거부 → 계정 기능 제한? 데이터 삭제? → 정책이 침묵

연구의 의의

- ▶ "개인정보처리방침이 어렵다"는 주관적 불만이 아니라
 - 129,856개 정책 자동 분석 → "어떤 내용이 얼마나 빠져 있는가"를 정량화
 - 규제 당국·연구자·사용자 모두에게 객관적 근거 제공

Conclusion

& Q / A

- ▶ PolicyPulse: SRL + 2단계 XLNet → 절(clause) 수준 세밀 추출
 - 기존 단락 분류 방식 대비 훨씬 구체적인 정보 제공
 - Weighted avg F1 0.97 / 모든 카테고리 precision·recall 0.92 이상

5가지 잠재적 응용 분야

- ▶ 정책 완전성 검사 — 법적 필수 항목 자동 체크
- ▶ 짧은 공지(Short Notice) 자동 생성
- ▶ 개인정보 영양 정보 라벨 (식품 성분표 스타일)
- ▶ 자동 질의응답 시스템 / 사용자 선호도 자동 확인

한계점 및 향후 과제

- ▶ 영어 전용 → 한국어 등 다국어 지원 필요
- ▶ 문장 간 관계 분석 불가 / GPT-4 비교 미수행
- ▶ 코드·데이터 공개: github.com/crisp-du/ppevo

방법론

- ▶ Q. SRL 모델 fine-tuning 없이 써도 괜찮은가?
 - 프레임 추출 자체는 충분. 분류는 XLNet이 따로 담당하므로 구조적 문제 없음
- ▶ Q. XLNet 채택 이유는?
 - 사전 실험에서 BERT·전통 분류기 대비 프레임 분류 성능 우수. TABLE I 참고

결과

- ▶ Q. F1 0.97인데 틀리는 케이스는?
 - DR·UAED 카테고리 상대적으로 낮음. 학습 데이터 적고 타 카테고리 문장과 혼동
- ▶ Q. ChatGPT-4와 비교는?
 - GPT-3.5만 비교. 저자도 최신 LLM과 깊은 비교는 향후 과제라고 명시

활용

- ▶ Q. 한국어 적용? → 현재 영어 전용. 한국어 BERT + 주식 데이터 추가 필요
- ▶ Q. 가장 충격적인 발견? → 60% USER_MECHANISM 미기재 / 75% CONSEQUENCE 미기재

- ▶ [1] Adhikari et al., "PolicyPulse: Precision Semantic Role Extraction for Enhanced Privacy Policy Comprehension," NDSS 2025.
- ▶ [2] Harkous et al., "Polisis: Automated Analysis and Presentation of Privacy Policies Using Deep Learning," USENIX 2018.
- ▶ [3] Cui et al., "PoliGraph: Automated Privacy Policy Analysis using Knowledge Graphs," USENIX 2023.
- ▶ [4] Wilson et al., "The Creation and Analysis of a Website Privacy Policy Corpus (OPP-115)," ACL 2016.
- ▶ [5] Yang et al., "XLNet: Generalized Autoregressive Pretraining for Language Understanding," NeurIPS 2019.
- ▶ [6] Bhatia et al., "Mining Privacy Goals from Privacy Policies Using Hybridized Task Analysis," ACM TOCHI 2016.
- ▶ [7] Princeton Privacy Crawl (PPCrawl) Corpus — github.com/citp/privacy-crawl