

PolicyPulse

Precision Semantic Role Extraction for
Enhanced Privacy Policy Comprehension

Andrick Adhikari · Sanchari Das · Rinku Dewri
University of Denver

NDSS 2025 · Network and Distributed System Security Symposium
Paper Review · 2026.05

MK4MAX44

학회 NDSS 2025

주제 개인정보 자동 분석

성능 F1 Score 0.97

규모 129,856개 정책

코드 github.com/crisp-du/ppevo

목 차

01	연구 배경 & 선행 연구	슬라이드 3-5
02	Methodology	슬라이드 6-14
03	Results & Analysis	슬라이드 15-22
04	Conclusion	슬라이드 23-25
05	Q & A	슬라이드 26-28
06	References	슬라이드 29-30

Table of Contents

논문	PolicyPulse — NDSS 2025
저자	Adhikari · Das · Dewri (Univ. of Denver)
주제	개인정보처리방침 자동 정보 추출 (SRL 기반)
규모	129,856개 정책 / 3,970만 프레임 분석
성능	Weighted Avg F1 = 0.97 달성
핵심	60% 정책이 USER_MECHANISM 미기재

핵심 방법론	
SRL	AllenNLP SRLBert — 프레임 추출
XLNet	2단계 분류 — SKIP/KEEP → 5-class
역할	16가지 프라이버시 역할 매핑
증강	textaugment 동의어 대체 (소수 클래스)

연구 배경

& 선행 연구

현실: 아무도 안 읽는 긴 문서

- ▶ 평균 개인정보처리방침 길이: 약 2,500~4,000단어 → 전부 읽는 데 30분 이상 소요
 - 연간 방문 사이트 전체 정책 다 읽으면 76일 걸린다는 연구 (McDonald & Cranor 2008)
 - 94%의 사용자가 동의 버튼 전에 안 읽음 / 42%는 "읽기 불가능"이라고 응답
 - 상위 500개 웹사이트 평균 독해 수준: 대학교 2학년 이상 (Flesch-Kincaid 기준)
 - Apple 개인정보처리방침 30,000단어 / Google 약 27,000단어로 매년 증가 추세

용어 개인정보처리방침: 서비스가 사용자 데이터를 어떻게 수집·사용·공유하는지 설명하는 법적 문서

용어 Flesch-Kincaid: 텍스트 가독성 지수. 12 이하가 대학원 수준. 정책 평균은 약 14~16

법 강화로 정책이 더 복잡해지는 악순환

- ▶ GDPR (2018, EU): 정보 주체 6가지 권리·13가지 고지 항목 명시 의무 → 정책 길이 증가
 - CCPA (2020, 캘리포니아): 판매 거부권·삭제권·차별 금지·연간 공개 보고 조항 추가
 - LGPD (2020, 브라질) / PIPL (2021, 중국) / 한국 개인정보보호법 2023년 개정
 - 법이 강화될수록 정책은 더 길어지고 → 사용자는 더 이해하기 어려워지는 역설
 - >>#Legal-Notice 의무화: 수집 목적·보유 기간·제3자 제공 여부 등을 명시해야 하는 법적 의무

용어 CCPA: California Consumer Privacy Act. 50만 달러 이상 매출 기업 적용. 위반 시 건당 \$7,500

기술적 해결 시도의 한계 → PolicyPulse의 출발점

- ▶ 단락 분류 도구(Polisis 등): "이 단락이 개인정보 관련인가/아닌가" 이진 판단만 가능
 - 실제로 필요한 것: "내 위치 데이터를 누가, 왜, 어떤 방법으로, 언제까지 수집하나"
 - SRL이 문장의 술어·행위자·대상·방법·시점을 동시에 추출 → 개인정보처리방침과 구조적 궁합

용어 NLP(Natural Language Processing): 자연어 처리. 컴퓨터가 인간 언어를 이해·분석하는 AI 분야

도구	주요 기법	세부 역할 추출	범용성	확장성
Polisis□(2018)	OPP-115 기반□딥러닝 분류	✗ 단락 수준만	✗ 분류 전용	△
PoliGraph□(2023)	NER + 지식그래프	△ 관계만 추출	✗ 특화됨	○
PolicyLint	규칙 + 논리 분석	✗	✗ 모순 탐지만	△
PurPliance	SRL (목적절 한정)	△ FPCU만	✗	△
★ PolicyPulse	SRL + XLNet□2단계 분류	✓ 16가지 역할	✓ 5가지 응용	✓

SRL: Semantic Role Labeling (의미역 레이블링) / NER: Named Entity Recognition (개체명 인식)

PolicyPulse가 기존 도구보다 나은 핵심 이유

- ▶ SRL 기반이라 "누가(AGENT) · 무엇을(DATA) · 어떻게(MECHANISM) · 언제(TRIGGER)" 동시 추출 가능
 - 단락 수준 분류: "이 단락에 데이터 수집 내용이 있다/없다" 수준만 판단 가능
 - 역할 추출까지 하면 실제로 어떤 데이터를 누가 어떻게 수집하는지 상세히 알 수 있음

각 도구의 구체적 한계

- ▶ Polisis: 107가지 세부 분류 지원하지만 각 분류가 YES/NO 이진 플래그 — 역할 구조 없음
 - PoliGraph: 지식 그래프로 관계 추출하지만 "제3자와 데이터 공유함" 수준, 어떤 데이터인지 모름
 - PurPliance: SRL 최초 도입했지만 "data collection" 목적절(purpose clause)만 분석하여 범위 매우 좁음
 - >>지식 그래프(Knowledge Graph): 개체(entity)와 관계(relation)를 노드-엣지 구조로 표현하는 그래프 데이터베이스

Methodology

Step 1 SRL (Semantic Role Labeling) — 구조 파싱

- ▶ AllenNLP SRLBert로 정책 문장에서 프레임(술어+인수 구조) 추출
 - 정책당 평균 70문장 × 문장당 평균 4.3 프레임 = 정책당 평균 305.7 프레임
 - 동사(술어) 하나당 프레임 1개 생성 → 문장에 동사 여러 개이면 여러 프레임 동시 생성
 - fine-tuning 없이 PropBank 사전 학습 모델 그대로 사용 (개인정보 동사와 궁합 좋음)
 - >>"We collect location data through cookies" → ARG0(We), V(collect), ARG1(location data), ARGM-MNR(cookies)

Step 2 프레임 분류 — 관련성 및 카테고리 판정

- ▶ XLNet 2단계: Level1 (SKIP/KEEP 이진) → Level2 (FPCU/TPSC/UCC/UAED/DR 5-class)
 - 2단계인 이유: SKIP 72.6% 데이터 불균형 → 단계 분리로 소수 클래스 집중 학습
 - 학습 데이터: OPP-115 기반 13,946개 수동 주석 프레임 / 10-겹 교차 검증
 - >>XLNet: 순열 기반 자기회귀 LM. BERT보다 양방향 문맥 + 자기회귀 특성 동시 보유

Step 3 프라이버시 역할 매핑 — 의미 추출

- ▶ PropBank 인수(ARG0·ARG1·ARGM-MNR 등) → 16가지 프라이버시 전용 역할로 변환
 - 146개 동사 × 카테고리별 매핑 테이블 수동 구축 (같은 ARG도 동사·카테고리에 따라 의미 다름)
 - 예: "collect" ARG1 → DATA / "share" ARG1 → THIRD_PARTY_ENTITY (카테고리: TPSC)
 - >>PropBank: 영어 동사 인수 구조 표준화 자원. ARG0=행위자, ARG1=대상, ARGM=수식어

Step 4 대규모 적용 — 완전성 분석

- ▶ Princeton Privacy Crawl (PPCrawl) — 130,604개 사이트 중 최신 1개 = 129,856개
 - 총 39,702,767개 프레임 → KEEP 추출 → 역할별 등장 여부 집계 → 누락 통계 산출
 - >>PPCrawl: 프린스턴대 공개 데이터셋. 2020년 전후 130만+ 사이트 정책 수집본




Fig. 1. Overview of privacy-specific role extraction in PolicyPulse

Fig.1 왼쪽: SRL 단계

- ▶ 입력 문장에서 SRL이
- ▶ 3개의 프레임 생성
 - frame1: include (FPCU)
 - frame2: use (SKIP)
 - frame3: collect (FPCU)

Fig.1 오른쪽: 역할 변환

- ▶ FPCU 프레임에서
- ▶ ARG0 → FIRST_PARTY
- ▶ ARG1 → DATA
- ▶ ARGM-MNR → MECHANISM
- ▶ ARGM-TMP → USER_TRIGGER

핵심 관찰

- ▶ 문장 하나에서 여러
- ▶ 프레임 동시 생성됨
- ▶ SKIP 프레임(frame2)은
- ▶ 분류 단계에서 제거
- ▶ → 관련 정보만 남김

ARG0: PropBank 표기. 술어의 주체(Agent) 역할. "We collect data"에

사용 모델: AllenNLP SRLBert — 선택 이유

- ▶ PropBank 코퍼스 기반 사전 학습 (약 50,000개 술어, 1,118개 동사 커버)
 - fine-tuning 없이 AllenNLP 제공 사전 학습 모델 그대로 사용 (도메인 적응 불필요)
 - 개인정보처리방침 동사("collect", "share", "disclose", "retain" 등) PropBank에 잘 정의됨
 - >>AllenNLP: Allen Institute for AI 개발 NLP 라이브러리. BERT 기반 SRL·NER·공참조 해소 모델 포함
 - >>PropBank: Penn Treebank 기반 동사 의미역 표준화 코퍼스. ARG0=행위자, ARG1=피행위자 등

실제 예시 — 문장 1개에서 프레임 3개 생성

- ▶ "We may collect location info through cookies when you use our service"
 - frame1 (include): [ARG1: IP address and GPS data] [V: include] → SKIP (서비스 설명)
 - frame2 (use): [ARG0: you] [V: use] [ARG1: our service] → SKIP (사용자 행위)
 - frame3 (collect): [ARG0: We] [V: collect] [ARG1: location info] [ARGM-MNR: through cookies] → KEEP(FPCU)
 - >>ARGM-MNR: Manner 수식어. "쿠키를 통해" / ARGM-TMP: 시간 / ARGM-PRP: 목적 / ARGM-ADV: 부사

정량 결과 및 분포

- ▶ 129,856개 정책 / 정책당 평균 305.7 프레임 / 총 39,702,767개 프레임 생성
 - 학습 데이터(OPP-115): 10,717문장 → 48,783 프레임 → 146개 관련 동사 필터 → 최종 13,946개
 - 전체 프레임 분포: SKIP 74.5% / FPCU 10.2% / TPSC 8.8% / UCC 4.0% / UAED 1.3% / DR 1.1%
 - 동사 146개 선정 기준: OPP-115 학습 데이터에 실제 등장한 동사 중 개인정보 관련성 수동 확인

용어 OPP-115: 115개 웹사이트 정책에 12개 프라이버시 카테고리로 수동 주석한 ACL 2016 공개 데이터셋

왜 2단계로 나뉘었나? — 클래스 불균형 해결

- ▶ 학습 데이터: SKIP 72.6%(10,401건) / FPCU 10.2% / TPSC 8.8% / UCC 4.0% / UAED 1.3% / DR 1.1%
 - 6-class 직접 분류 시 UAED(182건)·DR(160건)은 전체의 1%대 → SKIP에 압도당해 학습 실패
 - Level1 이진 분류 → Level2 5-class 분류: 각 단계가 자기 역할에만 집중할 수 있음
 - Level1 후 SKIP 폐기 → Level2 입력에서 SKIP 비율 0% → 클래스 불균형 극적으로 완화
 - >>클래스 불균형(Class Imbalance): 학습 데이터에서 특정 레이블이 지나치게 많아 모델 편향 발생

5가지 KEEP 카테고리 — KEEP 프레임 내 비율

- ▶ FPCU (First Party Collection/Use): 서비스 제공자 직접 수집·사용 → 45% (가장 많음)
 - TPSC (Third Party Sharing/Collection): 광고사·분석사 등 제3자 공유 또는 수집 → 17%
 - UCC (User Choice/Control): 옵트인·옵트아웃·쿠키 설정 등 사용자 선택권 → 13%
 - UAED (User Access/Edit/Deletion): 데이터 접근·수정·삭제 권리 — GDPR Art.17 → 5%
 - DR (Data Retention): 보존 기간·방식·파기 절차 → 5%
 - >>GDPR Article 17 "삭제권": 개인이 서비스에 자신의 데이터 삭제를 요청할 수 있는 권리

XLNet 학습 설정 및 모델 선택 근거

- ▶ XLNet-base / batch size 16 / 6 epochs / max sequence length 128 토큰
 - 검증 손실(validation loss) 기준으로 6 epoch 중 최적 모델 선택 (과적합 방지)
 - 사전 실험 비교: BERT → XLNet보다 낮음 / SVM·Naive Bayes → XLNet보다 현저히 낮음

용어 XLNet: Permutation Language Modeling 기반. BERT의 마스크 토큰 의존성 한계를 극복한 모델

Category	Frame			Frame with sentence context (FSC)			FSC with custom attn. mask			FSC augmented			FSC augmented (ensemble)			FSC augmented (two-level)		
	pr	re	f1	pr	re	f1	pr	re	f1	pr	re	f1	pr	re	f1	pr	re	f1
SKIP	0.96	0.90	0.93	0.94	0.93	0.93	0.85	0.95	0.89	0.95	0.90	0.92	0.95	0.92	0.93	0.99	0.98	0.98
FPCU	0.67	0.83	0.72	0.56	0.64	0.56	0.29	0.43	0.33	0.70	0.76	0.72	0.78	0.82	0.79	0.92	0.95	0.93
TPSC	0.70	0.77	0.70	0.59	0.71	0.59	0.38	0.36	0.34	0.70	0.79	0.74	0.75	0.84	0.79	0.92	0.94	0.93
UAED	0.36	0.10	0.15	0.37	0.18	0.20	0.22	0.18	0.16	0.75	0.97	0.84	0.62	0.70	0.65	0.93	0.93	0.92
UCC	0.74	0.79	0.74	0.52	0.61	0.56	0.31	0.30	0.29	0.78	0.96	0.86	0.74	0.80	0.76	0.93	0.93	0.93
DR	0.25	0.23	0.24	0.50	0.33	0.32	0.39	0.18	0.23	0.71	0.99	0.83	0.64	0.68	0.65	0.89	0.95	0.92
macro avg	0.61	0.61	0.58	0.58	0.57	0.53	0.41	0.40	0.37	0.77	0.89	0.82	0.74	0.79	0.76	0.93	0.95	0.94
weighted avg	0.88	0.86	0.86	0.84	0.86	0.84	0.72	0.80	0.74	0.89	0.88	0.88	0.90	0.89	0.89	0.97	0.97	0.97

TABLE I
XLNET NESTED CROSS-VALIDATION PERFORMANCE SCORES FOR DIFFERENT FRAME CLASSIFICATION TRAINING METHODS. PR: PRECISION, RE: RECALL, F1: F1-SCORE

uses two instances of XLNet. The evaluations employed a 10-fold cross-validation approach, utilizing a 9:1 train:test split ratio. The training and test data sets were maintained consistently across all methods. For each configuration, the XLNet model was trained for 6 epochs, utilizing a random 9:1 train:validation split on the training data set. We chose a 6 epoch training duration as, beyond this, validation loss rises while training loss still decreases, suggesting overfitting to training data. Following 6 epochs per fold, the optimal model (selected via validation loss) was tested, providing 10 performance estimates that we average for a final value.

3) *Performance Evaluation:* The average precision (pr), recall (re), and F1-score (f1) of all the methods are shown in Table I. The initial approach used only the frames’ text as input for model training (‘Frame’ column of Table I). While achieving a strong F1-score of 0.93 for the SKIP category, performance was notably low for other categories. Particularly, the UAED and DR categories exhibited F1-scores of only 0.15 and 0.24, respectively. Sentence context can significantly influence the frame category. Therefore, we next explored two methods to introduce such contexts in the model–(i) ‘Frame with sentence context (FSC)’: frame text combined with the sentence, and (ii) ‘FSC with custom attn. mask’: same as the previous but with addition of a custom attention mask for the XLNet input layer. The attention mask assigns a value of 0 to sentence phrases that are not present in the frame. Both methods show improved precision for the DR category, but there is an overall precision drop in all categories for method (ii). Method (i) also did not yield much performance improvement.

Variation in category performance shows influence of instance frequency during training. This is particularly apparent in the consistent superior precision and recall of the SKIP category, which has the highest instance frequency. To tackle

Category	pr	re	f1
LEVEL 1			
SKIP	0.99	0.98	0.98
KEEP	0.93	0.96	0.94
macro avg	0.96	0.97	0.96
weighted avg	0.97	0.97	0.97
LEVEL 2			
FPCU	0.98	0.98	0.98
TPSC	0.99	0.98	0.98
UAED	0.98	0.98	0.98
UCC	0.98	0.98	0.98
DR	0.96	0.97	0.96
macro avg	0.98	0.98	0.98
weighted avg	0.98	0.98	0.98

TABLE II
XLNET NESTED CROSS-VALIDATION PERFORMANCE SCORES FOR LEVEL 1: SKIP-KEEP BINARY CLASSIFICATION AND LEVEL 2: FPCU, TPSC, UCC, UAED, AND DR CLASSIFICATION WITHIN KEEP FRAMES. PR: PRECISION, RE: RECALL, F1: F1-SCORE

context, with synthetically generated training instances for low frequency categories. This approach proved to be effective in distinguishing between closely related frame categories such as UCC and UAED, or FPCU and TPSC, where differentiation is often challenging. Notably, precision and recall also remained consistent regardless of the category.

The disparity in the F1-scores, especially between SKIP frame identification and the rest (KEEP category), indicates the need to better discriminate between them. This prompted us to explore a two-level approach. The first level performed a binary classification to identify SKIP vs. KEEP frames, and the second level predicted the practice type from the five selected categories for KEEP frames. The two levels are realized as two XLNet models, both models trained to classify frames with sentence context. To ensure balance in instance counts, the low-frequency categories were augmented to match the instance count of the highest-frequency category.

TABLE I 읽는 법

- ▶ 행 = 4가지 학습 방법
- ▶ 열 = 카테고리별 F1

▶ Frame only

- 기본 프레임 텍스트만
- UAED F1 = 0.15 (최저)

▶ FSC Augmented

- 데이터 증강 후
- UAED 0.15 → 0.84

▶ FSC (Ensemble)

- 앙상블로도 한계

▶ ★ FSC (Two-Level)

- 최종 채택 방법
- 전체 F1 = 0.97

TABLE II

- ▶ Level1 따로: macro 0.96
- ▶ Level2 따로: macro 0.98

- 두 단계 모두 독립적
- ▶ 고성능 확인

F1-score: 정밀도(Precision)와 재현율(Recall)의 조화평균. 1에 가까울수록 좋

데이터 불균형 문제 해결

- ▶ SKIP이 72.6% → 6-class 직접 분류 시 모델이 SKIP에만 편향됨
 - Two-Level로 SKIP/KEEP 분리 → 각 단계가 자기 문제에만 집중
 - 결과: UAED F1 0.15 → 0.92 (약 6배 향상), DR 0.24 → 0.92

용어 클래스 불균형: 학습 데이터에서 특정 레이블이 지나치게 많을 때 모델이 다수 클래스에 편향되는 문제

데이터 증강의 역할

- ▶ UAED(182건), DR(160건)은 절대적으로 샘플 부족
 - 동의어 교체: "collect" → "gather", "obtain" 등
 - 문맥 기반 단어 치환: textaugment 라이브러리 활용
 - 증강 없이는 UAED 0.15에서 멈춤 → 증강이 핵심 요소

개인적으로 인상적이었던 부분

- ▶ UAED가 원래 F1 0.15였다는 게 놀라웠음 — 학습 데이터 182건이면 사실상 학습이 안 됨
 - 근데 증강 + 2단계 구조로 0.92까지 끌어올린 게 이 논문의 진짜 기여라고 생각
 - >>textaugment: 텍스트 데이터 증강 라이브러리. 동의어·문맥 대체 등 다양한 방법 지원

변환 원리: PropBank 인수 → 프라이버시 역할 (카테고리·동사에 따라 다름)

▶ "collect" 동사 + FPCU 카테고리:

- ARG0 → FIRST_PARTY_ENTITY (서비스 제공자: "We", "Company", "The Service")
- ARG1 → DATA (수집되는 정보: "email", "location", "browsing history", "IP address")
- ARGM-MNR → MECHANISM (수집 방법: "through cookies", "via API", "automatically")
- ARGM-TMP → USER_TRIGGER (수집 조건: "when you use our service", "upon registration")
- ARGM-PRP → PURPOSE (수집 목적: "to improve our services", "for analytics")

용어 ARGM-PRP: PropBank Purpose 수식어. "to provide better service"처럼 목적을 나타내는 절

16가지 프라이버시 역할 전체 목록 — 카테고리별

▶ FPCU: DATA / FIRST_PARTY_ENTITY / MECHANISM / PURPOSE / USER_TRIGGER

- TPSC: THIRD_PARTY_ENTITY / SHARING_TERMS / DATA / MECHANISM
- UCC: OPT_IN_MECHANISM / OPT_OUT_MECHANISM / CONSEQUENCE
- UAED: USER_MECHANISM / DATA_SUBJECT / LOCATION
- DR: TIME_PERIOD / RETENTION_PROCESS / RETENTION_TERMS
- >>USER_MECHANISM: 사용자가 직접 데이터를 관리하는 방법. "email us", "settings page" 등

역할별 실제 예시 (원문 텍스트)

▶ DATA: "your name, email address, phone number, and payment information"

- MECHANISM: "through the use of cookies, web beacons, and similar technologies"
- THIRD_PARTY_ENTITY: "with our advertising partners, including Google and Facebook"
- TIME_PERIOD: "for up to three years after your account is deleted"
- CONSEQUENCE: "you may not be able to access certain features of our services"

같은 동사, 다른 카테고리 → 완전히 다른 매핑

▶ "share" + TPSC: ARG2→THIRD_PARTY_ENTITY / "share" + FPCU: ARG2→PURPOSE

- 이 차이가 자동화 불가 이유 → 146개 동사 전수 수동 매핑 테이블 구축 필요

용어 SHARING_TERMS: 데이터 공유 조건·방식 역할. "under strict confidentiality agreements" 등

기반 데이터셋: OPP-115 — 왜 이걸 선택했나

- ▶ 115개 웹사이트 정책 / 12개 카테고리로 수동 주석된 공개 데이터셋 (ACL 2016)
 - 공개 데이터셋 중 프라이버시 정책에 특화된 가장 광범위한 주석 코퍼스
 - 12개 OPP-115 카테고리를 PolicyPulse의 6개 카테고리(SKIP/FPCU/TPSC/UCC/UAED/DR)로 재매핑
 - >>OPP-115: Online Privacy Policies 115개. 각 단락에 데이터 유형·목적 등 12개 카테고리로 태그됨

프레임 생성 및 주석 과정 — 4단계

- ▶ ① OPP-115 10,717문장 → SRLBert로 48,783 프레임 생성
 - ② 146개 관련 동사 기준 필터링 → 적합 프레임 추출 (관련 없는 동사 제거)
 - ③ 최종 13,946개 프레임에 SKIP/FPCU/TPSC/UCC/UAED/DR 수동 주석
 - ④ 독립 검증: 경력 5년+ 연구자 2명 별도 주석 → Cohen Kappa로 신뢰도 확인
 - 주석 단계별 소요 시간: 약 6개월 (프라이버시 정책 주석 경력 3년+ 연구자 전담)

용어 Cohen Kappa: 주석자 간 일치도 측정 지수. 0=우연 수준 / 1=완전 일치. 0.6 이상이면 신뢰 가능

카테고리별 분포 — 불균형의 심각성

- ▶ SKIP 10,401 (74.5%) / FPCU 1,417 / TPSC 1,230 / UCC 556 / UAED 182 / DR 160
 - UAED 182건: 전체의 1.3% → 6-class 직접 분류 시 모델이 UAED 학습 거의 못 함
 - 데이터 증강(textaugment): 동의어 치환·문맥 대체로 UAED·DR 샘플 인위적 확대

용어 textaugment: 파이썬 텍스트 증강 라이브러리. WordNet 동의어 대체, 문맥 기반 단어 삽입 지원

평가 방식 — 10-겹 교차 검증

- ▶ 데이터를 10등분 → 9개로 학습, 1개로 테스트 → 10번 반복 → 평균 성능 보고
 - 6 epoch 훈련 / 각 fold 내 검증 손실 최저 epoch 선택 (조기 종료 효과)

용어 과적합(Overfitting): 학습 데이터에만 성능 좋고 새 데이터에 약한 현상. 교차 검증으로 탐지 가능

Results

& Analysis

방법	SKIP	FPCU	TPSC	UCC	UAED	DR	W.Avg
Frame only	0.93	0.72	0.70	0.74	0.15	0.24	0.86
FSC Augmented	0.92	0.72	0.74	0.86	0.84	0.83	0.88
FSC (Ensemble)	0.93	0.79	0.79	0.76	0.65	0.65	0.89
★ FSC (Two-Level)	0.98	0.93	0.93	0.93	0.92	0.92	0.97

★ 최종 채택. Level1 macro avg F1: 0.96 / Level2 macro avg F1: 0.98 / W.Avg = Weighted Average

핵심 수치 해석 — 왜 Two-Level이 압도적으로 좋은가

- ▶ UAED: 학습 데이터 182건 → Frame only에서 F1 0.15 (사실상 학습 실패)
 - FSC Augmented(증강): 0.15 → 0.84 (데이터 증강이 소수 클래스에 결정적)
 - FSC Two-Level: 0.84 → 0.92 (2단계 구조가 추가로 8% 향상)
 - Ensemble: 오히려 0.65로 하락 → 단순 앙상블은 불균형 문제 해결 못함

비교 관점 — 기존 도구와의 차이

- ▶ Polisis 전체 F1 (OPP-115 기준): ~0.77 → PolicyPulse 0.97로 크게 앞섬
 - 하지만 단순 비교 주의: Polisis는 단락 분류, PolicyPulse는 프레임 분류 → 작업 범위 다름
 - >>Weighted Average: 각 클래스의 샘플 수에 비례해 가중 평균한 F1. SKIP이 많아서 높게 나올 수 있음

Role	Description
DATA	Information about individuals, users, or subjects, which may include personal, sensitive, or non-personal information
FIRST_PARTY_ENTITY	The organization directly interacting with users, responsible for data collection and use
THIRD_PARTY_ENTITY	An external organization or entity in collaboration with the first-party entity
MECHANISM	The procedures and methods used by first-party or third-party entities to gather user data
PURPOSE	The specific reason for data collection, use and sharing
SHARING_TERMS	The conditions and agreements that govern the sharing of user data with third parties
USER_TRIGGER	Actions or events by users that may trigger data collection, use, or sharing
OPT_IN_MECHANISM	A method or process by which a user can provide explicit consent for the collection or use of their data
OPT_OUT_MECHANISM	A method or process by which a user can choose to decline or stop the collection or use of their data
CONSEQUENCE	The potential outcomes or effects of user choices or actions
USER_MECHANISM	The methods and processes available to users for accessing, editing, and deleting their data
USER_OPERATION	The actions permitted for users to control their data, including access, edit, delete, or management of subsets
RETENTION_PROCESS	The procedures and methods followed by the organization for the storage and management of user data over time
RETENTION_TERMS	The specified terms and conditions that dictate how long user data will be retained by the organization
TIME_PERIOD	A defined duration specifying how long user data will be retained by the organization
LOCATION	The physical or digital location of a particular action; the action can be collection, use, or sharing of data

TABLE III
PRIVACY-SPECIFIC ROLES MAPPED FOR FRAME ARGUMENTS IDENTIFIED BY SEMANTIC ROLE LABELING

핵심 역할 요약

- ▶ DATA
 - 개인·민감 정보 총칭
- ▶ (이름·위치·이메일 등)
- ▶ MECHANISM
 - 수집 방법·절차
- ▶ (쿠키·API·로그 등)
- ▶ USER_MECHANISM
 - 사용자가 직접
- ▶ 데이터 관리하는 방법
- ▶ (설정 페이지·이메일 등)
- ▶ CONSEQUENCE
 - 옵트인/아웃 결과
- ▶ (서비스 제한·데이터 삭제)
- ▶ USER_TRIGGER
 - 수집 발생 조건
- ▶ (서비스 이용 시·가입 시)

왜 중요한가

- ▶ USER_MECHANISM이
- ▶ 60% 정책에서 누락
- ▶ → GDPR 위반 소지




Fig. 2. Left: number of total and KEEP frames in the policies, and Right: Total number of frames against KEEP frames across all the policies; frame count capped at the 90th percentile value

semantic frames from these sentences. We observed an average of ≈ 305.744 semantic frames per policy, with 25% of policies having over 403 frames, and some reaching up to 6,148 frames. Semantic frames are mental structures aiding language comprehension. When a text contains numerous frames, it raises the cognitive load for readers, which can contribute to comprehension difficulties often encountered with privacy policies. This is difficult to mitigate in traditional policies due to the lack of mechanisms for filtering information based on preferences. We observed that, on average, the ratio of the number of semantic frames to the number of sentences in a policy is 4 : 1. However, this ratio can also reach higher values, such as 14 : 1 observed in the case of *clothing-dropship.com* in the year 2016. This implies that readers, on average, encounter four times more frames than sentences. A 75th percentile value of 4.8 suggests that this holds true for most website policies.

Privacy-specific Relevance: We observed that our classi-

Category	Mean	Std. Dev.	Q1	Q2 (Median)	Q3
FPCU	47.989	16.566	38.235	48.889	57.143
TPSC	32.549	16.654	22.034	31.579	40.625
UCC	12.604	9.344	6.667	12.121	17.778
UAED	2.270	5.203	0.000	0.000	3.030
DR	4.589	6.541	0.000	2.041	7.692

TABLE IV
PRACTICE TYPE COMPOSITION STATISTICS FOR KEEP FRAMES

the total number of semantic frames in the policy increases. Relatively, policies with lower number of semantic frames have a higher proportion of frames retained. Thus, practice-specific information is dispersed over a relatively smaller portion of a policy’s text.

Categorical Composition: The next phase of our analysis is to investigate the trend of frame practice type composition. For each policy, we computed the percentage of each practice type category among all the KEEP frames in the policy. Table IV shows that, on average, nearly 48% of the KEEP frames are FPCU, followed by TPSC with an average of 33%. The 75th percentile value (Q3) for FPCU implies that nearly a quarter of the policies have more than 57.143% of their KEEP frames labeled as FPCU. Relative to other categories, FPCU and TPSC information have higher presence in terms of semantic information. We observed that 25% of the policies have more than 18% of their KEEP frames labeled as UCC. Additionally, the quartile values for UCC frames indicate that policies communicate user control and choice information to users in some capacity. However, DR and UAED frames are missing in 25% of the KEEP frames. The median for UAED indicates that access, edit, and delete semantic frames are absent in 50% of the policies. The rest of the policies have a relatively low portion of UAED frames, indicating this category to be the most under-addressed at the lowest granular composition level of policies.

Categorical Semantic Correlation: Sentences featuring frames within a consistent practice category foster a cohe-

Fig.2 왼쪽 그래프

- ▶ 전체 vs KEEP 프레임
- ▶ 정책별 분포
- ▶ 총 프레임: 오른쪽으로
- ▶ 길게 치우친 분포
- ▶ → 정책마다 길이 편차
- ▶ 매우 큼


Fig.2 오른쪽 그래프

- ▶ KEEP 프레임 분포
- ▶ (90th percentile 기준)
- ▶ 중위수(median) = 30
- ▶ → 절반의 정책은
- ▶ 30개 이하 KEEP

TABLE IV

- ▶ KEEP 프레임 중 카테고리
- ▶ 별 비율 (평균)
- ▶ FPCU 45% / TPSC 17%
- ▶ UCC 13% / UAED 5%
- ▶ → UAED가 가장 적음

중위수(Median): 데이터를 크기 순으로 정렬했을 때 정중앙 값. 극단값에 덜 민감



with respect to the terms of retention (RETENTION_TERMS), period of retention (TIME_PERIOD), and process of retention (RETENTION_PROCESS). In nearly 50% of the policies, UAED semantic frames often do not explicitly mention the DATA accessible and editable by users. Approximately 60% of the policies fail to convey the USER_MECHANISM for access, edit, and deletion, and 90% of the policies do not specify the LOCATION associated with the USER_MECHANISM.

Both FPCU and TPSC frames often contain PURPOSE information, but policies frequently fail to communicate the SHARING_TERMS associated with third-party information sharing. The MECHANISM for both first-party and third-party collection is absent in nearly 40% of the policies. Furthermore,

Fig.3 읽는 법

- ▶ 행·열 = 5개 카테고리
- ▶ 숫자 = 공출현 비율
- ▶ 1.0 = 자기 자신

주요 관찰

- ▶ FPCU ↔ TPSC: 0.64
 - 같은 문장에서
- ▶ 1자·3자 수집이
- ▶ 함께 나오는 경우
- ▶ 매우 흔함
- ▶ FPCU ↔ DR: 0.63
 - 데이터 수집 언급 시
- ▶ 보존 기간도 함께
- ▶ 나오는 편
- ▶ UAED ↔ DR: 0.47
 - 삭제 권리 + 보존
- ▶ 기간은 자주 같이
- ▶ 나옴 (연관성 높음)

시사점

- ▶ 카테고리 간 공출현이
- ▶ 높으면 분류가 어려움
- ▶ → Two-Level 구조가
- ▶ 더 필요한 이유

분석 규모 및 방법

- ▶ 130,604개 웹사이트 → 사이트당 가장 최신 정책 1개 선택 = 129,856개 정책
 - 총 39,702,767개 프레임 / 정책당 평균 305.7 프레임 / KEEP 평균 30개 (전체의 약 10%)
 - "완전성" 측정 기준: 특정 역할이 정책에 최소 1회 이상 등장하면 완전(1), 없으면 불완전(0)
 - >>PPCrawl 데이터: 130만+ 사이트 크롤링 → 최신 정책만 남기면 129,856개

핵심 역할 누락 비율 — 가장 충격적인 발견

- ▶ 50%: UAED 프레임 0개 — 사용자 데이터 삭제·접근 권리를 정책에 한 줄도 안 씀
 - 60%: USER_MECHANISM 미기재 — "어떻게 데이터 접근/삭제하나요?"를 설명 안 함
 - 75%: CONSEQUENCE 미기재 — 옵트아웃 시 어떤 변화가 생기는지 설명 없음
 - 40%: MECHANISM 없음 — 쿠키·SDK·픽셀 등 데이터 수집 방법 미기재
 - 20%: USER_TRIGGER 미기재 — 데이터 수집 발생 시점·조건 미명시

용어 CONSEQUENCE: 옵트인·아웃 결과 역할. "data will be deleted", "service may be limited" 등

UAED 분포 분석 (Fig.2 bar chart 참조)

- ▶ 전체 정책 50%: UAED 프레임 0개 → 삭제 관련 내용이 한 줄도 없음 (중위수 = 0)
 - 90th percentile 기준: UAED 프레임 수 3개 이하 → 상위 10% 정책도 매우 적음
 - FPCU는 95%+ 정책에 등장 (데이터 수집 자체는 거의 다 언급) → 공개 의지는 있음
 - 하지만 "사용자가 뭘 할 수 있는지"(UAED·UCC·CONSEQUENCE)는 무시되는 경향

카테고리별 정책 간 공출현 패턴 (Fig.2·Fig.3 연계 해석)

- ▶ 대부분 정책은 FPCU + TPSC를 함께 기재 (공출현 0.64) → 수집하면 제3자 공유도 언급
 - UAED + DR 공출현 0.47: 삭제 언급 시 보존 기간도 같이 나오는 편 (논리적 연결)
 - CONSEQUENCE는 UCC와도 공출현 낮음 → 선택권 설명하면서도 결과는 빠뜨리는 사이트

용어 공출현(Co-occurrence): 두 항목이 같은 정책에 함께 등장하는 비율. 1.0=항상 함께 등장

GDPR·CCPA가 보장하는 권리를 정책이 설명 안 함

- ▶ UAED = 접근·수정·삭제 권리 → GDPR Article 17 "삭제권(Right to be Forgotten)"
 - 50% 사이트가 이 법적 권리를 정책에 명시조차 안 함 → 이 연구의 핵심 발견
 - USER_MECHANISM 60% 누락: 삭제권이 있다고 해도 어떻게 행사하는지를 안 알려줌
 - 즉 "권리는 있는데 어떻게 쓰는지 모른다" 상태가 절반 이상 사이트의 현실
 - >>Right to be Forgotten: GDPR Article 17. 서비스에 자신의 개인 데이터 삭제를 요청 가능한 권리

CONSEQUENCE 75% 누락의 현실적 의미

- ▶ 광고 수신 거부(옵트아웃) 버튼을 눌렀을 때 실제로 뭐가 달라지는지 안 알려줌
 - 계정 기능 제한? 일부 데이터만 삭제? 완전 삭제? → 정책이 침묵
 - "동의"를 눌렀을 때도 마찬가지로 — 서비스가 무엇을 하는지 결과를 안 씀

용어 CONSEQUENCE 역할: 옵트인·아웃 결과. "your access will be limited", "data will be deleted" 등

연구의 진짜 의의 — 정량적 증거

- ▶ "개인정보처리방침 읽기 어렵다"는 주관적 불만 → 수치로 "얼마나 빠져있나" 제시
 - 129,856개 정책의 역할별 누락률을 자동 산출 → 인간이 직접 읽어야 알 수 있는 것을 자동화
 - 규제 당국: 위반 후보 자동 선별 / 기업: 작성 시 체크리스트 / 연구자: 비교 분석
 - 이 분야에서 이 정도 규모의 정량적 증거를 낸 연구가 이전에 없었다는 게 핵심 기여

용어 컴플라이언스 감사(Compliance Audit): 정책·법규 준수 여부를 체계적으로 점검하는 절차

사용자 입장에서의 함의

- ▶ 지금 당장 실천할 수 있는 것: 서비스 가입 전 USER_MECHANISM이 있는지 확인
 - "How to delete my account" 또는 "Contact us to request data deletion" 같은 문구 검색
 - CONSEQUENCE가 없으면 옵트아웃 결과가 불명확 → 어떤 효과를 기대할지 모름

용어 개인정보 자기결정권: 자신의 개인정보 수집·이용·제공 여부를 스스로 결정할 권리 (한국 헌법적 권리)

이 연구 이후의 흐름 — 2025년 현재

- ▶ GDPR 집행이 강화되면서 개인정보 자동 분석 도구에 대한 수요 증가 중
 - EU AI Act(2024 발효)와 개인정보 정책의 교차점: AI 시스템의 학습 데이터 투명성 요구
 - PolicyPulse 류의 도구가 AI 시스템 개인정보 감사에도 활용될 가능성 높음

실험 방법

- ▶ 야후(Yahoo) 개인정보처리방침을 ChatGPT-3.5와 PolicyPulse 각각에 입력, 결과 비교
 - ChatGPT-3.5에게 "정책의 핵심 정보를 추출해달라" 프롬프트 제공
 - >>프롬프트(Prompt): LLM에 입력하는 지시문. 프롬프트 품질에 따라 결과 크게 달라짐

ChatGPT-3.5 결과의 구체적 문제

- ▶ 제3자 데이터 공유(TPSC) 관련 내용을 요약에서 빠뜨림 → 누락(omission)
 - 원문에 없는 구체적 광고 파트너 목록을 생성 → hallucination(환각) 발생
 - 요약 문장이 자연스럽게 읽기 쉬워 오히려 신뢰하기 쉬운 게 더 위험할 수 있음
 - >>Hallucination(환각): LLM이 실제 없는 내용을 있는 것처럼 생성하는 현상. 신뢰성 문제의 핵심

PolicyPulse 결과 — 환각 없는 추출

- ▶ 원문에 있는 프레임만 추출 → 없는 내용 생성 안 함 (결정론적 추출)
 - 각 역할(DATA·MECHANISM·CONSEQUENCE·THIRD_PARTY_ENTITY 등) 단위로 분리
 - 출력 형태가 구조화된 역할 목록 → 기계 처리와 검증이 용이
 - 단점: GPT-4·Claude 등 최신 LLM과 비교 없음 / 자연어 설명 아님 (기술적 출력)

개인적 생각

- ▶ LLM 출력이 자연스러울수록 오히려 환각을 구별하기 어려움 → 법적 문서에서 치명적
 - PolicyPulse의 룰 기반 매핑은 느리고 어렵지만 "원문 근거" 보장이 핵심 강점

왜 법적 문서에서 환각이 특히 치명적인가

- ▶ "제3자에게 데이터를 공유하지 않습니다"라는 환각 → 사용자가 실제 공유가 있어도 모름
 - 개인정보 처리방침은 법적 구속력 있는 문서 → 잘못된 요약이 법적 분쟁 원인이 될 수 있음
 - 의료·금융 분야처럼 정확성이 요구되는 도메인일수록 구조적 추출의 가치가 높음

용어 법적 구속력(Legal Binding): 계약·약관·정책에 동의하면 그 내용을 따를 의무가 생기는 것

실용적 관점 — 어느 도구를 쓸 것인가

- ▶ 빠른 일반 요약이 필요하다면: GPT-4 (자연스럽고 읽기 쉬움)
 - 데이터 수집 역할의 정확한 추출·검증이 필요하다면: PolicyPulse (원문 근거 보장)
 - 하이브리드: PolicyPulse로 구조화 추출 → LLM으로 자연어 설명 생성 (최상의 조합)

① 정책 완전성 검사 (Policy Completeness Checking)

- ▶ 법적 필수 항목(GDPR의 USER_MECHANISM·UAED 등)이 정책에 포함됐는지 자동 체크
 - 기업 법무팀이 정책 초안 작성 시 실시간 누락 항목 경고
 - 규제 당국이 대규모 컴플라이언스 감사 시 수동 검토 없이 위반 후보 선별

용어 컴플라이언스(Compliance): 법·규정 등 준수 여부. 위반 시 GDPR은 전 세계 매출의 4% 벌금

② 짧은 공지(Short Notice) 자동 생성

- ▶ 긴 정책에서 핵심 역할(DATA·MECHANISM·CONSEQUENCE 등)만 추출해 1페이지 요약본 자동 생성
 - EU·영국 ICO가 권장하는 "Layered Privacy Notice" 방식: 짧은 공지 + 전문 링크
 - >>Layered Privacy Notice: 정책을 짧은 요약층·상세층으로 나누는 구조. EU 권장 방식

③ 개인정보 영양 정보 라벨 (Privacy Nutrition Label)

- ▶ 식품 성분표처럼 데이터 수집 항목·목적·기간을 표준 형식으로 제시
 - Carnegie Mellon 등에서 제안된 레이블 형식: PolicyPulse 추출 결과를 자동으로 채울 수 있음
 - >>Privacy Nutrition Label: 데이터 수집 내용을 아이콘·항목으로 시각화. CMU 연구팀 제안

④ 자동 질의응답 (Contextual Q&A System)

- ▶ "이 서비스가 내 위치 데이터를 광고사에 공유하나요?" → 원문 프레임 기반 자동 답변
 - 환각 없이 원문 근거 답변 / 특정 역할(TPSC·MECHANISM) 검색으로 정확도 확보

용어 RAG(Retrieval-Augmented Generation): 외부 정보를 검색해 LLM 답변에 근거 추가하는 방식

⑤ 사용자 선호도 자동 대조 (Preference Matching)

- ▶ 사용자가 설정한 프라이버시 선호(예: 마케팅 수신 거부)와 정책 CONSEQUENCE 역할 자동 비교
 - 일치 여부 알림 시스템: "이 서비스는 옵트아웃 시 기능이 제한됩니다" 같은 경고 자동 생성

Conclusion

핵심 기여 1 — 방법론적 발전

- ▶ SRL + 2단계 XLNet → 단락 수준 분류에서 절(clause) 수준 세밀 추출로 발전
 - 기존: "이 단락에 데이터 수집 내용이 있다" / 이제: "누가·무엇을·어떻게·언제"까지
 - Weighted avg F1 0.97 / 모든 카테고리 precision·recall 0.92 이상 달성
 - >>절(Clause) 수준 분석: 문장 전체가 아닌 술어 중심 의미 단위(프레임)로 쪼개서 분석

핵심 기여 2 — 규모와 발견

- ▶ 129,856개 정책 / 3,970만+ 프레임 처리 / 16가지 역할 / 5가지 응용 분야 제안
 - 기존 SRL 기반 연구(PurPliance): 5개 정책 202문장 → 규모 차이가 압도적
 - 50%+ 정책에서 UAED 완전 누락 / 75%에서 CONSEQUENCE 미기재 발견
 - 규제 당국이 활용 가능한 대규모 정량적 증거를 최초로 제공

용어 Open Source: 코드·데이터 공개 → 재현 가능성 확보. github.com/crisp-du/ppevo

보고 나서 든 생각 — 솔직한 감상

- ▶ "SRL이 개인정보처리방침에 잘 맞나?" 처음에 의구심이 있었는데 읽을수록 맞았음
 - PropBank의 ARG0·ARG1·ARGM 구조가 "누가·무엇을·어떻게"와 거의 1:1 대응이라 딱 맞음
 - 제일 인상적: UAED F1 0.15 → 0.92. 데이터 182건을 증강 + 2단계 구조로 극복한 것
 - 근데 이게 개인정보처리방침에만 적용 가능한 건지, 다른 법적 문서에도 쓸 수 있는지 궁금함
 - 한국어 정책에 적용하려면 결국 주석 데이터 구축이 가장 큰 벽인데 그게 현실적으로 어려울 듯

보안 공부 관점에서 본 시사점

- ▶ 프라이버시 보안은 기술 취약점뿐 아니라 "정보 비대칭" 문제도 다뤄야 함
 - 사용자가 데이터를 어떻게 다루는지 모르면 → 동의 행위 자체가 아무 의미 없음
 - PolicyPulse 같은 도구가 보급되면 개인정보 감사(audit)의 자동화가 현실화될 수 있음
 - 실제 웹사이트 개인정보처리방침을 직접 확인할 때 이 논문의 분석 틀이 유용한 체크리스트가 됨
- ▶ 코드·데이터 공개: github.com/crisp-du/ppevo · NDSS 2025 채택

현재 한계 ① — 영어 전용

- ▶ 영어 SRL 모델 + 영어 OPP-115 주식 데이터 기반 → 한국어·중국어 등 다국어 지원 불가
 - 한국어 적용하려면: ① 한국어 SRL 모델(KLUE-SRL 등) ② 한국어 정책 주식 데이터 필요
 - 한국 개인정보보호위원회 대상 컴플라이언스 체크에 활용하려면 반드시 해결해야 할 과제

용어 KLUE-SRL: Korean Language Understanding Evaluation. 한국어 NLP 벤치마크 데이터셋 모음

현재 한계 ② — 문장 내 분석만 가능

- ▶ 문장 간 관계 파악 불가: "앞 문장에서 수집한 데이터를 이 문장에서 제3자와 공유한다" 연결 못 함
 - SRL 자체의 구조적 한계 → 담화 수준(discourse-level) 분석은 별도 연구 필요
 - 실제 정책에서 "수집 → 사용 → 공유 → 보존" 흐름 파악을 위해선 이 한계 극복 필요

용어 담화 수준 분석(Discourse Analysis): 문장을 넘어 여러 문장·단락 간 의미 연결을 분석하는 NLP 작업

현재 한계 ③ — 최신 LLM 비교 없음

- ▶ GPT-3.5만 비교 → GPT-4·Claude 3·Gemini 등 2024~2025년 최신 모델과 차이가 불명확
 - 최신 LLM은 환각이 크게 줄었다는 평가 → PolicyPulse의 "환각 없음" 강점이 얼마나 차별화되는지 미지수
 - 저자도 "향후 연구 과제"로 명시 → 후속 비교 연구 기대됨

향후 연구 방향

- ▶ 사용자 평가 연구 미수행: 생성된 짧은 공지·라벨이 실제로 이해하기 쉬운지 확인 안 됨
 - A/B 테스트나 실험 참가자 연구(user study) 통해 실용성 검증 필요
 - LLM 결합: PolicyPulse가 프레임 추출 → LLM이 자연어로 설명 생성하는 하이브리드 방식 유망

용어 User Study: 실제 사용자를 대상으로 인터페이스·정보 이해도 등을 측정하는 평가 실험

Q & A

예상 질문 & 답변

Q. SRL 모델을 fine-tuning 없이 써도 괜찮은가?

- ▶ 프레임 추출(Step 1)은 PropBank 사전 학습 모델로 충분 → fine-tuning 불필요
 - "collect", "share", "disclose", "retain" 등 개인정보 동사가 PropBank에 이미 잘 정의됨
 - 분류(Step 2) + 역할 매핑(Step 3)이 도메인 특화를 담당 → 파이프라인의 모듈 분리 설계 장점
 - 단, PropBank에 없는 신조어 동사("anonymize", "pseudonymize" 등)는 커버 안 될 수 있음

Q. XLNet을 선택한 근거가 있나?

- ▶ 논문 내 사전 실험(ablation study): BERT·SVM·Naive Bayes 대비 F1 전반적으로 우수
 - 개인정보처리방침의 복잡한 조건절("when you use our service...")에서 차이 두드러짐
 - XLNet의 순열 기반 모델링이 조건·시간·방법 수식어가 많은 법적 텍스트에 적합
 - >>Ablation Study: 모델 구성 요소를 하나씩 제거해가며 각 요소의 기여도를 측정하는 실험

Q. 146개 동사 매핑은 어떻게 구축했나?

- ▶ OPP-115 학습 데이터에서 실제 등장한 동사들만 대상 → 전수 수동 분석
 - 각 동사의 PropBank 프레임셋 참조 → 카테고리별 ARG 번호 → 역할 매핑 테이블 작성
 - 완전 자동화가 아닌 수작업 → 신뢰성 높지만 새 동사 추가 시 테이블 수동 업데이트 필요

Q. 학습 데이터 주석 품질은 어떻게 보장했나?

- ▶ 경력 3년+ 연구자 주석 / 경력 5년+ 연구자 2명 독립 검증 / 불일치 토론 합의
 - Cohen Kappa 계수 보고: 카테고리별 일치도 측정 → 주석의 객관성 확보 근거

용어 Inter-Annotator Agreement(IAA): 여러 주석자가 같은 데이터에 동일한 레이블을 얼마나 달았는지 측정

Q. F1 0.97인데 어떤 케이스에서 틀리나?

- ▶ DR·UAED 카테고리에서 상대적으로 낮음 (각 F1 0.92 → 전체 중 가장 낮음)
 - 이유: 학습 데이터 부족 + Fig.3 공출현 분석상 UAED↔DR 공출현 높아 혼동 잦음
 - 예: "We retain your data for 30 days after you delete your account" → UAED? DR? 둘 다?
 - False Positive 주로 발생: FPCU 문장을 TPSC로 오분류 (제3자 언급이 있는 경우)

Q. GPT-4·Claude와 비교하지 않은 이유?

- ▶ 논문 제출 시점(2023~2024년 초)에 GPT-4 API 비용·접근성 제한이 있었을 가능성
 - 저자도 "최신 LLM과의 비교는 향후 과제"로 명시 → 후속 연구에서 다뤄질 것
 - 현실적 고려: GPT-4는 컨텍스트 길이 제한 → 30,000단어 정책을 통째로 넣기 어려움

용어 Prompt Chunking: 긴 문서를 LLM에 넣을 때 여러 청크로 나눠 처리하는 방식. 일관성 손실 위험 있음

Q. 한국어 개인정보처리방침에 적용 가능한가?

- ▶ 현재는 불가 — 영어 SRL + 영어 OPP-115 주석만 사용
 - 한국어 적용 경로: ① KLUE-SRL 기반 한국어 프레임 추출 ② 한국어 정책 주석 데이터 구축
 - 한국 개인정보보호법·PIPA 대상 컴플라이언스 자동화에 활용 가능성 높음

용어 KLUE(Korean Language Understanding Evaluation): 한국어 NLP 벤치마크. SRL·NER·MRC 등 8가지 과제 포함

Q. 가장 충격적인 발견은?

- ▶ 75%의 정책이 CONSEQUENCE 미기재 — 옵트아웃 결과가 원지 설명 자체를 안 하는 사이트
 - 사용자가 "광고 수신 거부" 눌러도 실제로 뭐가 바뀌는지 정책이 침묵한다는 것
 - 규제 강화로 정책이 길어졌는데 오히려 핵심 사용자 권리 설명은 줄어드는 역설

- ▶ [1] Adhikari et al., "PolicyPulse: Precision Semantic Role Extraction for Enhanced Privacy Policy Comprehension," NDSS 2025.
 - ★ 이 발표의 주요 논문. NDSS 2025 채택. 코드: github.com/crisp-du/ppevo
- ▶ [2] Harkous et al., "Polisis: Automated Analysis and Presentation of Privacy Policies Using Deep Learning," USENIX Security 2018.
 - OPP-115 기반 딥러닝 분류. 107개 세부 카테고리. 단락 수준 분류 도구의 대표 사례
- ▶ [3] Cui et al., "PoliGraph: Automated Privacy Policy Analysis using Knowledge Graphs," USENIX Security 2023.
 - NER + 지식 그래프 기반. 데이터 관계 추출 특화. 역할 추출은 제한적
- ▶ [4] Wilson et al., "The Creation and Analysis of a Website Privacy Policy Corpus (OPP-115)," ACL 2016.
 - PolicyPulse 학습 데이터 기반. 115개 정책 / 12개 카테고리 / 수동 주석 공개 데이터셋
- ▶ [5] Yang et al., "XLNet: Generalized Autoregressive Pretraining for Language Understanding," NeurIPS 2019.
 - PolicyPulse Step 2 분류기 기반 모델. 순열 기반 언어 모델링으로 BERT 한계 보완
- ▶ [6] Bhatia et al., "Mining Privacy Goals from Privacy Policies Using Hybridized Task Analysis," ACM TOCHI 2016.
 - >>PurPliance 선행 연구. SRL을 처음 개인정보처리방침에 적용한 연구. 목적절 한정
- ▶ [7] McDonald & Cranor, "The Cost of Reading Privacy Policies," I/S: A Journal of Law and Policy 2008.
 - 연간 76일 소요 추산 연구. 개인정보처리방침 자동 분석 연구의 출발점이 된 논문
- ▶ [8] Princeton Privacy Crawl (PPCrawl) — github.com/citp/privacy-crawl
 - Step 4 대규모 분석에 사용된 130만+ 사이트 정책 크롤링 데이터셋. 공개 접근 가능