

PolicyPulse

Precision Semantic Role Extraction for
Enhanced Privacy Policy Comprehension

Andrick Adhikari · Sanchari Das · Rinku Dewri | University of Denver

NDSS 2025 · Paper Review · 2026.05

목차

01	Introduction
02	State of the Art
03	Methodology
04	Results
05	Conclusion
06	References

Table of Contents

본 발표는 NDSS 2025에 게재된 PolicyPulse 논문을 리뷰합니다.

개인정보처리방침의 SRL 기반 자동 정보 추출과
130만 개 정책 분석 결과를 다룹니다.

Introduction

& State of the Art

- 연구 배경: 개인정보처리방침의 비효율성
 - 개인정보처리방침은 법적 구속력을 지닌 문서이지만 평균 70문장의 복잡한 법률 언어로 작성
 - 사용자는 내용을 이해하지 못한 채 동의 → 가독성·보호성·접근성 모두 문제
- 기존 NLP 도구의 한계
 - 단락 수준 분류에 그침 → "데이터 수집 항목 있냐 없냐" 수준의 정보만 제공
 - 누가(FIRST_PARTY), 무엇을(DATA), 어떻게(MECHANISM) 수집하는지 세부 추출 불가
 - 특정 태스크 하나에만 특화 → 다른 응용에 재사용 불가
- 제안하는 해결법: PolicyPulse
 - SRL(Semantic Role Labeling, 의미역 레이블링) 기반 세밀한 정보 추출 파이프라인
 - 분류에서 끝내지 않고 문장 내 "누가·무엇을·왜·어떻게"를 역할 단위로 자동 추출
 - 범용 플랫폼 → 완전성 검사·요약 생성·Q&A·선호도 확인 등 다양한 응용 지원

- ▪ 분류(Classification) 기반
 - Polisis (Harkous et al., USENIX 2018): OPP-115 기반 단락 수준 분류. 데이터 수집/공유 등 범주 제공
 - 높은 정확도이나 "어떤 데이터를 누가 어떻게"는 알 수 없음 → 세부 추출 불가
- ▪ 정보 추출(Information Extraction) 기반
 - PoliGraph (Cui et al., USENIX 2023): NER로 데이터 유형·주체·관계 그래프 추출
 - PolicyLint / PoliCheck: 정책 내 모순·앱 행동 불일치 탐지에 특화. 범용 추출 목적 아님
- ▪ SRL 기반 (선행 연구)
 - Bhatia et al. (2016): 5개 정책 202개 문장 수작업 코딩 → 17개 의미역. 자동화 없음
 - PurPliance: 목적 절(purpose clause)에만 SRL 적용. 범위가 FPCU로 제한적
- ▪ 결론 및 PolicyPulse의 위치
 - 기존 도구들: 단일 태스크 특화 또는 자동화 미비
 - PolicyPulse: 분류 + 자동 SRL을 결합하여 다목적 정보 추출 플랫폼 실현

Methodology

- ▪ 사용 모델: AllenNLP SRLBert (BERT 기반 의미역 레이블링)
 - PropBank 코퍼스 기반 사전 학습 (약 50,000개 술어, 1,118개 동사)
 - 별도 fine-tuning 없이 AllenNLP 제공 사전 학습 모델 그대로 사용

추출 예시

- 문장: "We may collect location information through cookies when you use our service"
 - [ARG0: We] [V: collect] [ARG1: location information]
 - [ARGM-MNR: through cookies] [ARGM-TMP: when you use our service]
 - → 하나의 문장에서 "프레임 1(collect)" + "프레임 2(use)" 2개의 프레임 생성
- 정량적 결과
 - 정책당 평균 70문장 · 문장당 약 4개 프레임 → 정책당 평균 305.7개 프레임 추출
 - 129,856개 정책에서 총 39,702,767개 프레임 생성
 - 약 32%의 문장은 SKIP 프레임만 포함 (관련 정보 전혀 없음)

분류 단계	레이블	내용	F1 (Two-Level)
Level 1	SKIP	개인정보 무관 프레임 — 학습 데이터의 72.6%	0.98
Level 1	KEEP	5개 카테고리 중 하나에 해당하는 관련 프레임	0.94
Level 2	FPCU	1자 데이터 수집·사용 (First Party Collection/Use)	0.98
Level 2	TPSC	제3자 공유·수집 (Third Party Sharing/Collection)	0.98
Level 2	UCC	사용자 선택권·통제 — 옵트인/옵트아웃	0.98
Level 2	UAED	사용자 데이터 접근·수정·삭제	0.98
Level 2	DR	데이터 보존 기간 (Data Retention)	0.96

* XLNet을 채택한 이유: 사전 실험에서 BERT 기반 모델 및 전통 분류기 대비 프레임 분류 성능이 우수

- 146개 동사에 대해 PropBank 인수 정의 → 프라이버시 전용 역할로 변환
 - 같은 동사라도 프레임 카테고리(FPCU / TPSC 등)에 따라 다른 역할로 매핑

예시: "collect" 동사 (FPCU 카테고리)

- ARG0 (행위 주체) → FIRST_PARTY_ENTITY
- ARG1 (행위 대상) → DATA
- ARG-MNR (방법) → MECHANISM
- ARG-M-TMP (시점) → USER_TRIGGER

추출되는 16가지 프라이버시 역할 (주요)

- DATA · FIRST_PARTY_ENTITY · THIRD_PARTY_ENTITY · MECHANISM · PURPOSE
- SHARING_TERMS · USER_TRIGGER · OPT_IN_MECHANISM · OPT_OUT_MECHANISM
- CONSEQUENCE · USER_MECHANISM · TIME_PERIOD · LOCATION (외 3종)

- 기반 데이터셋: OPP-115
 - 115개 웹사이트 정책에 12개 카테고리로 주석된 공개 데이터셋 (ACL 2016)
 - 10,717개 문장에서 SRLBert로 48,783개 프레임 생성 후 146개 관련 동사 기준 필터링
 - 최종 13,946개 프레임 수동 주석
- 주석 품질 관리
 - 주석 담당: 프라이버시 정책 주석 경력 3년+ 연구자
 - 독립 검증: 경력 5년+ 연구자 2명
- 카테고리별 분포 및 증강
 - SKIP 10,401 / FPCU 1,417 / TPSC 1,230 / UCC 556 / UAED 182 / DR 160
 - UCC·UAED·DR 저빈도 카테고리: 동의어 교체 + 문맥 기반 단어 치환으로 증강
- 평가 방식: 10-겹 교차 검증 (9:1 훈련/테스트)
 - 최적 모델: 각 fold당 검증 손실 기준으로 선택 (6 epoch 훈련)

Results

& Conclusion

방법	SKIP	FPCU	TPSC	UCC	UAED	DR	Weighted Avg
Frame only	0.93	0.72	0.70	0.74	0.15	0.24	0.86
FSC Augmented	0.92	0.72	0.74	0.86	0.84	0.83	0.88
FSC Aug (Ensemble)	0.93	0.79	0.79	0.76	0.65	0.65	0.89
★ FSC Aug (Two-Level)	0.98	0.93	0.93	0.93	0.92	0.92	0.97

★ 최종 채택 방법. Level1 macro avg F1: 0.96 / Level2 macro avg F1: 0.98

- 분석 규모
 - 130,604개 웹사이트 최신 정책 129,856개 · 총 39,702,767개 프레임 처리
 - 정책당 평균 306개 프레임 생성 → KEEP은 평균 30개 (약 10%)

정책 완전성 분석: 누락된 핵심 역할

- 50%의 정책: UAED 프레임 자체가 없음 (사용자 데이터 삭제 권리 전혀 미언급)
- 60%의 정책: USER_MECHANISM 미기재 (데이터 접근·수정·삭제 방법 불명확)
- 75%의 정책: CONSEQUENCE 미기재 (옵트인/아웃을 했을 때 어떤 결과인지 불명확)
- 40%의 정책: MECHANISM 없음 (데이터 수집 방법 미기재)
- 20%의 정책: USER_TRIGGER 미기재 (언제 수집되는지 명시 안 함)

ChatGPT-3.5 비교

- ChatGPT: 야후 정책 요약 시 제3자 공유 내용 누락 + 없는 내용 생성(hallucination)
- PolicyPulse: 원문 기반 추출 → 환각 없음
 - 단, GPT-4 등 최신 LLM과의 비교는 향후 연구 과제로 남김

- PolicyPulse: SRL + 2단계 XLNet 분류기를 결합한 정보 추출 파이프라인
 - 기존 단락 수준 분류 → 절(clause) 수준 세밀 추출로 발전
 - Weighted avg F1-score 0.97 달성 / 모든 카테고리에서 precision-recall 0.92 이상
- 5가지 잠재적 응용 분야
 - 정책 완전성 검사 / 짧은 공지(Short Notice) 자동 생성
 - 개인정보 영양 정보 라벨 / 자동 질의응답 / 사용자 선호도 자동 확인
- 한계점 및 향후 연구
 - 영어 전용 → 한국어 등 다국어 지원 필요
 - 문장 간 관계 분석 불가 (문장 수준 분석 한계)
 - ChatGPT-3.5와 비교했으나 GPT-4 등 최신 LLM과의 비교 미수행
 - 생성된 짧은 공지·영양 정보 라벨에 대한 실제 사용자 평가 연구 미수행
- 코드 및 데이터 공개: github.com/crisp-du/ppevo

- [1] Adhikari et al., "PolicyPulse: Precision Semantic Role Extraction for Enhanced Privacy Policy Comprehension," NDSS 2025.
- [2] Harkous et al., "Polisis: Automated Analysis and Presentation of Privacy Policies Using Deep Learning," USENIX Security 2018.
- [3] Cui et al., "PoliGraph: Automated Privacy Policy Analysis using Knowledge Graphs," USENIX Security 2023.
- [4] Wilson et al., "The Creation and Analysis of a Website Privacy Policy Corpus (OPP-115)," ACL 2016.
- [5] Yang et al., "XLNet: Generalized Autoregressive Pretraining for Language Understanding," NeurIPS 2019.
- [6] Bhatia et al., "Mining Privacy Goals from Privacy Policies Using Hybridized Task Analysis," ACM TOCHI 2016.
- [7] Princeton Privacy Crawl (PPCrawl) Corpus — github.com/citp/privacy-crawl